

Perbandingan antara Batuk yang Diminta dan Batuk yang Berlangsung Lama Suara untuk Mendeteksi Tuberkulosis

Aprianto Dwi Prasetyo*, Bagus Tris Atmaja, Dhany Arifianto dan Sakriani Saktis

*Institut Teknologi Sepuluh Nopember, Indonesia Email:

6009231008@student.its.ac.id , arifianto@its.ac.id

†Institut Sains dan Teknologi Nara, Jepang

Email: bagus.tris@naist.ac.jp , ssakti@is.naist.jp

Abstrak—Tuberkulosis (TB) menyebabkan sekitar 1,25 juta kematian pada tahun 2023, melebihi jumlah yang terdampak COVID-19. Alat diagnostik yang ada mahal dan tidak terjangkau di lingkungan dengan sumber daya terbatas, yang menyebabkan keterlambatan dan penularan yang berkelanjutan. Metode skrining yang cepat dan terjangkau sangat dibutuhkan untuk mengidentifikasi dan merujuk kasus TB yang dicurigai untuk konfirmasi. Salah satu pendekatan yang menjanjikan adalah pembelajaran mendalam menggunakan suara batuk, yang menawarkan solusi berbiaya rendah dan terukur. Namun, membangun model pembelajaran mendalam yang efektif sangat bergantung pada data, khususnya keseimbangan antara kualitas dan kuantitas data. Dua jenis dataset dievaluasi: data yang diminta (rekaman terawasi) dan data longitudinal (rekaman tidak terawasi). Hasil menunjukkan bahwa rekaman terawasi mencapai kinerja yang lebih tinggi daripada rekaman tidak terawasi ketika menggunakan ukuran data yang sama (akurasi 79% vs. 71%). Namun, peningkatan jumlah data tidak terawasi secara signifikan meningkatkan kinerja, mencapai akurasi 91%—menyoroti manfaat dari dataset yang lebih besar. Menariknya, penggabungan data yang diminta dan data longitudinal tidak meningkatkan kinerja, kemungkinan karena proporsi data yang diawasi terlalu kecil.

Saya. SayaPENDAHULUAN

Tuberkulosis (TB) adalah penyakit yang sangat menular dan tetap menjadi masalah kesehatan global utama. Pada tahun 2023, TB bertanggung jawab atas sekitar 1,25 juta kematian, menjadikannya kemungkinan penyebab kematian utama di seluruh dunia dari satu agen infeksi, melampaui COVID-19. Sebagai perbandingan, jumlah kematian akibat COVID-19 yang secara resmi dilaporkan kepada Organisasi Kesehatan Dunia (WHO) pada tahun 2023 adalah 320.000; saat ini tidak mungkin total untuk tahun 2024 akan melebihi angka ini untuk TB [1]. Di seluruh dunia, pengurangan bersih dalam tingkat kejadian TB antara tahun 2015 dan 2023 adalah 8,3%, jauh dari target Strategi Akhiri TB WHO yaitu pengurangan 50% pada tahun 2025. Mayoritas kasus TB terjadi di 30 negara dengan beban tinggi, yang secara kolektif menyumbang 87% dari kasus TB global pada tahun 2023. Beberapa negara ini diklasifikasikan sebagai negara berkembang, di mana tantangan sosial-ekonomi yang kompleks menghambat akses ke layanan kesehatan publik. Hambatan-hambatan ini menyulitkan pendeteksian, pengobatan, dan pengendalian TB secara efektif, yang seringkali menyebabkan perawatan yang tidak memadai dan penularan penyakit yang berkelanjutan [2].

Alat diagnostik TB yang ada saat ini seringkali mahal dan membutuhkan keahlian dan infrastruktur khusus. Di banyak negara berkembang, fasilitas perawatan kesehatan primer kekurangan sumber daya keuangan untuk menerapkan metode canggih ini untuk skrining cepat. Akibatnya, mereka harus bergantung pada teknik yang lebih lambat, lebih mendasar, tetapi terjangkau seperti analisis dahak [1]. Hal ini menyebabkan penundaan diagnosis yang berkepanjangan, meningkatkan risiko

Tuberkulosis (TB) menyebar dengan cepat di dalam masyarakat. Oleh karena itu, ada kebutuhan mendesak akan metode skrining yang terjangkau dan cepat yang dapat membantu mengidentifikasi individu yang kemungkinan menderita TB dan merujuk mereka untuk pengujian konfirmasi yang lebih komprehensif.

Penggunaan suara manusia sebagai biomarker untuk deteksi penyakit telah banyak dipelajari. Arifianto et al. [3] mengusulkan metode autoregresif yang bervariasi waktu untuk menganalisis gangguan bicara. Sasou dan Chen [4] menggabungkan penyaringan invers glotal dan pembelajaran mandiri untuk mendeteksi suara patologis. Atmaja dan Sasou [5] meningkatkan kinerja skor F1 dari penelitian sebelumnya pada dataset uji yang sama menggunakan pembelajaran ensemble. Untuk TB, berbagai penelitian telah menunjukkan potensi penggunaan suara batuk untuk mendeteksi penyakit pernapasan (misalnya, [6], [7]). Kedua penelitian ini menggunakan pembelajaran mendalam sebagai model utama. Dalam membangun model pembelajaran mendalam yang baik, beberapa faktor memengaruhi kualitas dataset, terutama empat aspek kualitas data: keseimbangan dataset, ukuran dataset, kualitas label, dan kontaminasi dataset [8].

Jenis rekaman yang digunakan untuk analisis batuk TB dapat berdampak pada kinerja. Adapun dataset yang akan digunakan dalam penelitian ini, terdapat dua jenis rekaman. Data pertama adalah batuk yang diminta, yang diperoleh dalam lingkungan terkontrol mengikuti prosedur standar, meskipun hanya mencakup sekitar 1,5% dari total dataset. Jenis data kedua adalah batuk longitudinal, yang direkam secara tidak diawasi, di mana pasien diminta untuk membawa telepon penelitian selama dua minggu untuk mengumpulkan suara batuk secara pasif di lingkungan rawat jalan [9]. Akibatnya, kualitas batuk longitudinal umumnya lebih rendah dibandingkan dengan batuk yang diminta.

Pengaruh data longitudinal telah dipelajari sebelumnya di domain lain, seperti perilaku mengemudi dan prediksi karisma [10], [11]. Namun, pengaruh data longitudinal pada prediksi TB berdasarkan batuk belum tersedia. Studi ini mengusulkan untuk menganalisis secara mendalam data longitudinal dan membandingkan hasilnya dengan data yang diminta, termasuk kombinasi keduanya.

II. METODE

A. Kumpulan Data

Dataset yang digunakan dalam penelitian ini adalah CODA TB DREAM Challenge Dataset [12]. Dataset akses terbuka ini diperoleh melalui platform Synapse, yang hanya mengizinkan akses kepada pengguna terautentikasi setelah melalui peninjauan oleh pengelola akses data.

Hanya peneliti dengan profil terkonfirmasi—yang mencakup koneksi ORCID, verifikasi identitas, dan penerimaan Janji Synapse—yang diberikan akses ke data yang diatur oleh Synapse. Pendekatan ini mendorong transparansi dan perlindungan privasi pasien serta keamanan data. Untuk melindungi informasi peserta, dataset telah dianonimkan, dengan semua detail demografis dan klinis dianonimkan. Dataset berisi dua jenis data berdasarkan cara data diperoleh, yang pertama adalah batuk yang diminta, yang diperoleh dalam lingkungan dan prosedur terkontrol. Yang lainnya adalah batuk longitudinal yang direkam dengan pendekatan tanpa pengawasan, di mana pasien diminta untuk membawa telepon studi selama dua minggu dan mengumpulkan suara batuk longitudinal di lingkungan rawat jalan menggunakan algoritma Hyfe [13] untuk mendeteksi dan mensegmentasi batuk. Dengan menggunakan algoritma ini, probabilitas suara eksplosif sebagai batuk manusia dihitung dan dilaporkan sebagai skor probabilitas 0 hingga 1 [9]. Dari kriteria probabilitas ini, kami hanya memilih data batuk dengan skor probabilitas di atas 0,95 untuk memastikan bahwa tidak ada suara lain selain batuk dalam dataset. Pemilihan batuk berdasarkan probabilitasnya telah terbukti bermanfaat dalam deteksi penyakit berbasis batuk lainnya [14]. Pada akhirnya, untuk sampel batuk yang diminta, jumlah sampel batuk adalah 9.232, dan untuk sampel batuk longitudinal, jumlah sampel batuk adalah 647.060. Kelas suara batuk yang terdapat dalam basis data ini adalah TB Positif dan TB Negatif berdasarkan standar referensi mikrobiologis, seperti yang disebutkan dalam dataset asli.

B. Fitur Akustik dan Praproses

Sebelum ekstraksi fitur akustik, rekaman audio batuk menjalani serangkaian langkah pra-pemrosesan. Awalnya, sampel audio diubah frekuensinya menjadi 16 kHz dari 44,1 kHz. Kemudian, kami menormalkan rentang sinyal audio ke -1 dan 1 dengan Normalisasi Min-Max, yang dilakukan dengan membagi setiap elemen dengan nilai absolut maksimum. Setelah itu, untuk memastikan keseragaman panjang input di semua sampel audio, setiap klip distandarisasi ke durasi tetap 1 detik. Dalam kasus di mana audio asli lebih pendek dari durasi target, kami menerapkan pengulangan padding, di mana sinyal audio diulang hingga panjang yang dibutuhkan tercapai.

Spektrogram Mel digunakan sebagai fitur akustik utama dalam penelitian ini, karena spektrogram Mel dihitung dengan menerapkan transformasi Fourier waktu singkat (STFT) dengan ukuran frame 64 ms, frame hop 16 ms, dan menggunakan fungsi jendela Hann. Untuk skala Mel, digunakan filterbank Mel 80 saluran yang mencakup rentang 125 Hz hingga 7,6 kHz. Contoh spektrogram Mel yang diekstrak untuk Non-TB dan TB ditunjukkan pada Gambar 2.

C. Model dan Pengaturan Pelatihan

Untuk semua percobaan, model yang sama digunakan, yaitu model LSTM sederhana [15] dengan beberapa modifikasi, arsitektur yang dimodifikasi diilustrasikan pada Gambar 1. Jaringan ini terdiri dari jaringan memori jangka panjang dan pendek (LSTM) dua lapis. Input pertama-tama dinormalisasi menggunakan normalisasi batch, kemudian masuk ke lapisan LSTM pertama, dan diproyeksikan ke dimensi tersembunyi 1024, kemudian dinormalisasi batch lagi dan diteruskan ke lapisan kedua.

Gambar 1: Arsitektur Jaringan LSTM

Lapisan LSTM, juga dengan dimensi tersembunyi 1024. Output yang sesuai dengan lapisan LSTM terakhir diekstrak dan diratakan. Setelah itu, lapisan dropout dengan tingkat 0,1 diterapkan. Terakhir, state tersembunyi dilewatkan melalui lapisan terhubung penuh yang memetakan 1024 state tersembunyi ke 2 output, yang mewakili TB Positif atau TB Negatif.

Pengaturan pelatihan sama untuk semua eksperimen. Data untuk setiap evaluasi (diminta, longitudinal, dan tipe campuran) dibagi menjadi 90% data pelatihan dan 10% data pengujian. Model dilatih pada satu GPU dengan ukuran batch 128, optimizer AdamW [16] digunakan dengan $\beta_1=0.8$, $\beta_2=0.999$, $\epsilon=10^{-6}$ dan tingkat pembelajaran $5e^{-4}$ meluruh secara eksponensial oleh 0.999875 Setiap epoch. Untuk fungsi kerugian, digunakan kerugian cross-entropy dengan bobot kelas yang dihitung, yang bertujuan untuk mengatasi ketidakseimbangan kelas dengan memberikan bobot yang lebih tinggi pada kelas minoritas. Mekanisme penghentian dini dengan nilai kesabaran lebih besar dari 5 diterapkan untuk mencegah overfitting. Checkpoint model dengan kerugian validasi terendah dipilih sebagai model akhir dan digunakan untuk evaluasi pada dataset pengujian.

D. Metrik Evaluasi

Beberapa metrik evaluasi digunakan untuk memberikan wawasan berbeda tentang kinerja pengklasifikasi, yaitu akurasi, ROC AUC, skor F1, sensitivitas, dan spesifisitas.

Ketepatan Akurasi mengukur seberapa sering pengklasifikasi secara keseluruhan memberikan hasil yang benar. Akurasi dihitung dengan mengambil jumlah total prediksi yang benar (baik true positive maupun true negative) dan membaginya dengan jumlah total prediksi. Dengan kata lain, akurasi memberi tahu kita seberapa sering model mendapatkan hasil yang benar. Namun, akurasi bisa menyesatkan, terutama ketika data tidak seimbang (misalnya, ketika ada lebih banyak kasus negatif daripada kasus positif). Sebuah model mungkin mendapatkan akurasi tinggi hanya dengan selalu memprediksi kelas mayoritas. Di sinilah metrik lain seperti F1-score berperan.

Skor F1 berfokus pada keseimbangan antara presisi (berapa banyak prediksi positif yang sebenarnya benar) dan recall (berapa banyak positif sebenarnya yang diidentifikasi dengan benar). Ini sangat berguna terutama ketika kita lebih peduli tentang *kelas positif* dan menginginkan keseimbangan antara mendeteksi hal positif dan menghindari alarm palsu.

Kepekaan Sensitivitas adalah ukuran kinerja yang digunakan dalam klasifikasi biner, terutama bermanfaat saat menangani data yang tidak seimbang. Ini memberi tahu kita seberapa baik sistem mengidentifikasi kasus positif (positif sejati) dengan benar. Sensitivitas yang lebih tinggi berarti lebih sedikit negatif palsu; dengan kata lain, pengklasifikasi lebih baik dalam menangkap

Gambar 2: Citra Mel-Spektrogram Batuk TB Negatif dan Batuk TB Positif

Kasus positif. Ini sangat penting dalam sistem medis, di mana terlewatnya deteksi pasien yang sakit (hasil negatif palsu) dapat memiliki konsekuensi serius.

Kekhususan, Di sisi lain, spesifisitas mengukur seberapa baik sistem tersebut mengidentifikasi kasus negatif (negatif sejati) dengan benar. Ini adalah proporsi sampel negatif aktual yang diprediksi dengan benar. Spesifisitas yang lebih tinggi berarti lebih sedikit positif palsu, dalam konteks sistem medis, lebih sedikit orang yang secara salah diberitahu bahwa mereka mungkin sakit dan membutuhkan pengujian lebih lanjut (seringkali tidak perlu).

Kurva ROC adalah grafik yang menunjukkan seberapa baik kinerja sebuah pengklasifikasi. Grafik ini memplot tingkat positif aktual (TPR, sama dengan sensitivitas) pada sumbu vertikal, dan tingkat positif palsu (FPR, sama dengan spesifisitas) pada sumbu horizontal. Kurva ROC membantu kita melihat keseimbangan antara mendeteksi positif sebenarnya (sensitivitas) dan menghindari alarm palsu (spesifisitas). Jika kurva melewati sudut kiri atas, pengklasifikasi tersebut sempurna. Jika terletak di sepanjang garis tengah, berarti pengklasifikasi tersebut tidak sempurna. 45 derajat jika garisnya diagonal, artinya pengklasifikasi menebak secara acak. Meskipun kurva ROC bermanfaat, penggunaannya bisa sulit ketika membandingkan model yang memiliki kinerja serupa. Itulah mengapa kita sering menggunakan area di bawah kurva ROC (AUC) sebagai angka tunggal untuk membandingkan model. AUC berkisar dari 0 hingga 1, nilai yang lebih tinggi berarti kinerja yang lebih baik, dan nilai yang mendekati 0,5 berarti model tersebut tidak lebih baik daripada tebakan acak.

III. RHASIL DANDISKUSI

A. Suara Batuk yang Diminta vs. Suara Batuk Longitudinal pada Jumlah Sampel yang Sama

Dalam skenario ini, suara batuk longitudinal dikurangi untuk mencapai ukuran sampel yang sama dengan batuk yang diminta. Kami menggunakan pengambilan sampel acak untuk mengambil sampel batuk longitudinal sebanyak batuk yang diminta. Untuk melaporkan hasil rata-rata, kami menjalankan

TABEL I: Hasil untuk Suara Batuk yang Diminta vs. Suara Batuk Longitudinal pada Jumlah Sampel yang Sama

Data	Ketepatan	ROC AUC	F1	Kepekaan	Kekhususan
Diminta	0,79	0,80	0,70	0,82	0,78
Membujur	0,71	0,72	0,62	0,73	0,71

Percobaan dilakukan 5 kali untuk pelatihan longitudinal. Oleh karena itu, hasil untuk data longitudinal pada Tabel I merupakan rata-rata dari 5 kali pelatihan longitudinal dengan set sampel yang berbeda.

Dari Tabel I, ketika menggunakan data yang sama (9.232 sampel), rekaman batuk yang diminta secara konsisten mengungguli data longitudinal di semua metrik yang dievaluasi. Perbedaan kinerja ini kemungkinan disebabkan oleh kondisi terkontrol di mana rekaman yang diminta dikumpulkan. Rekaman ini diperoleh dengan pengawasan personel studi, memastikan pengambilan audio yang konsisten dan berkualitas tinggi [9]. Sebaliknya, rekaman longitudinal lebih rentan terhadap variabilitas kualitas rekaman. Faktor-faktor seperti penempatan mikrofon yang tidak konsisten, kebisingan latar belakang lingkungan, dan potensi kehadiran individu lain yang batuk di dekat peserta dapat berkontribusi pada penurunan kualitas audio [17] dan, akibatnya, penurunan kinerja model.

TABEL II: Hasil untuk Suara Batuk yang Diminta vs. Suara Batuk Longitudinal pada Jumlah Sampel yang Berbeda

Data	Ketepatan	ROC AUC	F1	Kepekaan	Kekhususan
Diminta	0,79	0,80	0,70	0,82	0,78
Membujur	0,91	0,91	0,93	0,91	0,92

Gambar 3: Kerugian pelatihan dan validasi untuk model longitudinal menggunakan jumlah sampel yang sama dengan data yang diminta.

B. Suara Batuk yang Diminta vs. Suara Batuk Longitudinal pada Jumlah Sampel yang Berbeda

Dalam skenario ini, batuk longitudinal dan batuk yang diminta dilatih pada jumlah sampel yang berbeda, dengan masing-masing menggunakan dataset lengkap untuk setiap partisi. Setelah pelatihan, hasilnya ditempatkan pada Tabel II. Menggunakan dataset longitudinal lengkap (647.060 sampel) menghasilkan peningkatan kinerja yang signifikan, menunjukkan peningkatan sekitar 10% dibandingkan dengan data yang diminta saja. Seperti yang telah disebutkan sebelumnya, dataset batuk longitudinal menunjukkan variabilitas yang signifikan, termasuk perbedaan dalam posisi perangkat perekam relatif terhadap peserta, kebisingan latar belakang, dan keberadaan individu lain yang batuk di dekatnya [9]. Variabilitas ini berkontribusi pada kekayaan dataset, yang bermanfaat bagi model pembelajaran mendalam, karena biasanya model tersebut berkinerja lebih baik dengan data yang lebih besar dan lebih beragam [18]. Selain itu, variabilitas dalam data longitudinal dapat meningkatkan kemampuan model untuk melakukan generalisasi dan mengurangi overfitting. Meskipun data yang dikumpulkan menawarkan kualitas yang lebih tinggi karena kondisi perekaman yang terkontrol, skala dan variabilitas data longitudinal menjadi aset berharga ketika memanfaatkan teknik pembelajaran mendalam, hal ini diilustrasikan pada Gambar 6 dibandingkan dengan Gambar 3 dan Gambar 4. Pada Gambar 6, kerugian pelatihan dan validasi menurun bersamaan hingga penghentian dini menghentikan pelatihan, menunjukkan generalisasi yang baik. Sebaliknya, Gambar 3 dan Gambar 4 menunjukkan tren yang berbeda: sementara kerugian pelatihan terus menurun, kerugian validasi menurun dengan laju yang lebih lambat dan akhirnya menyimpang, menghasilkan kesenjangan yang lebih besar antara keduanya. Ini menunjukkan bahwa model mengalami overfitting pada data pelatihan dalam kasus ini. Lebih lanjut, jika data longitudinal dari Tabel I dibandingkan, kinerja meningkat hingga 20%.

Untuk lebih memahami seberapa baik setiap model merepresentasikan kelas yang berbeda, t-SNE digunakan untuk memvisualisasikan embedding [19]. Sampel acak sebanyak 200 titik data dari setiap kelas dipilih dan diplot dalam scatter plot. Embedding yang dihasilkan oleh model yang diminta (Lihat Gambar 5a) tidak menunjukkan pemisahan yang jelas antara kelas; titik-titik dari kelas yang berbeda tersebar dan tumpang tindih, sehingga sulit untuk membedakan satu kelas dari kelas lainnya. Sebaliknya, embedding yang dihasilkan oleh

TABEL III: Hasil penggabungan suara batuk yang diminta dan longitudinal

Data	Ketepatan	ROC AUC	F1	Kepekaan	Kekhususan
Diminta	0,79	0,80	0,70	0,82	0,78
Membujur	0,91	0,91	0,93	0,91	0,92
Gabungan	0,91	0,91	0,93	0,92	0,91

Model longitudinal (lihat Gambar 5b) menunjukkan pemisahan yang jauh lebih jelas, dengan titik data membentuk klaster yang berbeda berdasarkan kelas. Ini menunjukkan bahwa model longitudinal menangkap fitur yang lebih bermakna dan diskriminatif, sehingga mampu merepresentasikan kelas yang berbeda secara lebih efektif daripada model yang diminta.

Temuan mengenai penggunaan data yang kurang berkualitas (rekaman tanpa pengawasan) namun lebih terkuantifikasi yang menghasilkan kinerja lebih tinggi dibandingkan data berkualitas juga mendukung efektivitas data yang tidak masuk akal [20]: “Dengan sumber data yang sangat besar, data tersebut memuat detail-detailnya. Seperti yang dapat kita lihat pada Tabel II dan III, kuantitas data lebih penting daripada kualitas data untuk deteksi TB berdasarkan batuk.

C. Menggabungkan Suara Batuk yang Diminta dan Suara Batuk Longitudinal

Pada skenario terakhir ini, kami menggabungkan data yang diminta dan data longitudinal untuk melatih model, yang dapat memperoleh hasil yang lebih tinggi daripada pelatihan data longitudinal sebelumnya. Hasilnya ditempatkan pada Tabel III. Dari Tabel tersebut, terlihat bahwa penggabungan data yang diminta dan data longitudinal tidak menghasilkan peningkatan kinerja yang signifikan pada sebagian besar metrik. Satu-satunya peningkatan adalah pada skor sensitivitas, di mana data gabungan mencapai 0,01% lebih tinggi daripada data longitudinal. Pada skor spesifisitas, data gabungan mencapai skor yang lebih rendah daripada data longitudinal, sedangkan pada tiga metrik lainnya, skornya sama. Hal ini kemungkinan karena data yang diminta hanya mewakili sekitar 1,5% dari total dataset, sehingga pengaruhnya minimal dalam pelatihan model gabungan.

IV. CKESIMPULAN

Dalam makalah ini, kami meneliti eksperimen terstruktur tentang deteksi penyakit tuberkulosis melalui suara batuk. Dua metode berbeda...

Gambar 4: Kerugian pelatihan dan validasi untuk model yang diminta

(a) Model yang Diminta

(b) Model Longitudinal

Gambar 5: Visualisasi TSNE dari embedding untuk dua model berbeda

Berbagai jenis data dievaluasi, yaitu data yang diminta (rekaman terawasi) dan data longitudinal (rekaman tidak terawasi). Beberapa wawasan dapat diperoleh berdasarkan temuan tersebut. Pertama, rekaman terawasi memperoleh kinerja yang lebih tinggi daripada rekaman tidak terawasi dengan jumlah data yang sama. Kedua, ketika jumlah data tidak terawasi ditingkatkan, kinerja meningkat secara signifikan (akurasi 91%), menyoroti kontribusi data yang lebih besar. Ketiga, kombinasi data yang diminta dan data longitudinal tidak meningkatkan kinerja, mungkin karena jumlah data yang diminta terlalu sedikit. Penelitian selanjutnya dapat diarahkan untuk menstandarisasi pengumpulan data terawasi, serta mengevaluasi fitur dan arsitektur akustik lainnya.

APENGAKUAN

Makalah ini sebagian didasarkan pada hasil yang diperoleh dari proyek JST Nexus 2025 dan Hibah JSPS KAKENHI Nomor 24K0296. Kumpulan data yang digunakan untuk analisis yang dijelaskan disumbangkan oleh Dr. Adithya Cattamanchi di UCSF dan Dr. Simon Grandjean Lapierre di Universitas Montreal dan dihasilkan dalam kolaborasi dengan para peneliti di Universitas Stellenbosch (PI Grant Theron), Walimu (PI William Worodria dan Alfred Andama); Institut Ilmu Kedokteran dan Kesehatan De La Salle (PI Charles Yu), Program Tuberkulosis Nasional Vietnam (PI Nguyen Viet Nhung), Christian Medical College (PI DJ Christopher), Centre Infectiologie Charles Merieux Madagascar (PI Mihaja Raberahona & Rivonirina Rakotoarivelo), dan Institut Kesehatan Ifakara (PI Issa Lyimo & Omar Lweno) dengan pendanaan dari Institut Kesehatan Nasional AS (U01 AI152087), Yayasan Patrick J. McGovern dan Global Health Labs.

Gambar 6: Kerugian pelatihan dan validasi untuk model longitudinal menggunakan jumlah sampel penuh

RREFERENSI

- [1] Organisasi Kesehatan Dunia, "Laporan tuberkulosis global 2024," Organisasi Kesehatan Dunia, Laporan Teknis, 2024, Diakses: 12 Juni 2025. [Online]. Tersedia: <https://www.who.int/publications/i/item/9789240101531>.
- [2] N. Foster, A. Vassall, S. Cleary, L. Cunnam, G. Churchyard, dan E. Sinanovic, "Beban ekonomi diagnosis dan pengobatan TB di Afrika Selatan," *Ilmu Sosial & Kedokteran*, vol. 130, hlm. 42–50, 2015.
- [3] D. Arifianto, H. Setijono, dan Sekartedjo, "Analisis gangguan bicara menggunakan autoregresif yang bervariasi waktu," *Simposium Sistem Sirkuit Midwest.*, vol. 3, no. 2, hlm. 191–194, 2004, ISSN: 15483746.
- [4] A. Sasou dan Y. Chen, "Perbandingan Fitur Berbasis GIF dan SSL dalam Deteksi Suara Patologis," di dalam *INTERSPEECH 2023*, ISCA: ISCA, Agustus 2023, hlm.2893–2897.
- [5] BT Atmaja dan A. Sasou, "Deteksi Suara Patologis dari Vokal yang Dipertahankan: Pembelajaran Buatan Tangan vs. Pembelajaran Mandiri," *Konferensi Internasional IEEE 2025 tentang Akustik, Ucapan, dan Pemrosesan Sinyal.*, 2025.
- [6] G. Frost, G. Theron, dan T. Niesler, "TB atau bukan TB? Analisis batuk akustik untuk klasifikasi tuberkulosis," *Prosiding Konferensi Tahunan Asosiasi Komunikasi Lisan Internasional INTER-SPEECH*, jilid. 2022-September, tidak. September, hal. 2448– 2452, 2022, ISSN: 19909772. cetak: 2209.00934.
- [7] W. Xu, H. Yuan, X. Lou, Y. Chen, dan F. Liu, "Pemeriksaan Tuberkulosis Berbasis DMR-Net dengan Suara Batuk," *Akses IEEE*, vol. 12, no. Januari, hlm. 3960–3968, 2024, ISSN: 21693536.
- [8] T. He, S. Yu, Z. Wang, J. Li, dan Z. Chen, *Dari kualitas data ke kualitas model: Sebuah studi eksplorasi tentang pembelajaran mendalam.*, 2019. arXiv: 1906.11882 [cs.LG].
- [9] S.Huddart, V.Yadav, SK Sieberts, *dkk.*"Kumpulan data suara batuk yang diminta untuk pengujian triase tuberkulosis," *Data Ilmiah*, jilid. 11, tidak. 1, hal. 1149, 2024.
- [10] W. Wang, C. Liu, dan D. Zhao, "Seberapa banyak data yang cukup? Pendekatan statistik dengan studi kasus pada perilaku mengemudi longitudinal," *IEEE Trans. Intell. Veh.*, vol. 2, no. 2, hlm. 85–98, 2017, ISSN: 23798858.
- [11] A. Hernández, C. Araya, J. García, dan V. González, "Karisma pemimpin dan iklim tim yang afektif: peran moderasi pengaruh dan interaksi pemimpin," *Psikothema*, vol. 21, no. 4, hlm. 515–20, 2009.
- [12] S. Huddart, V. Yadav, SK Sieberts, *dkk.*"Analisis suara batuk yang diminta untuk pengujian triase tuberkulosis: Kumpulan data tantangan mimpi coda tb," *MedRxiv*, 2024.
- [13] C. Chaccour, I. Sánchez-Olivieri, S. Siegel, *dkk.* "Validasi sistem pemantauan batuk Hyfe: studi klinis multisenter," hlm. 1–11, 2025.
- [14] BT Atmaja, Zanjabila, Suyanto, WA Asmoro, dan A. Sasou, "Pembelajaran transfer lintas dataset COVID-19 dengan augmentasi data," *Jurnal Teknologi Informasi Internasional*, hlm. d, Februari 2025, ISSN: 2511-2104.
- [15] A. Hassan, I. Shahin, dan MB Alsabek, "Sistem deteksi Covid-19 menggunakan jaringan saraf berulang," dalam *Konferensi Internasional Komunikasi, Komputasi, Keamanan Siber, dan Informatika (CCCCI) 2020*, IEEE, 2020, hlm. 1–5.
- [16] I. Loshchilov dan F. Hutter, "Regularisasi peluruhan bobot yang terpisah," *arXiv preprint arXiv:1711.05101*, 2017.
- [17] P. Bottalico, J. Codino, LC Cantor-Cutiva, *dkk.* "Reproduksibilitas parameter suara: Pengaruh akustik ruangan dan mikrofon," *Jurnal Suara*, vol. 34, no. 3, hlm. 320–334, 2020, ISSN: 0892-1997.
- [18] Y.Ba, MV Mancenido, dan R.Pan, *Bagaimana keragaman data membentuk lanskap bobot jaringan saraf?* 2024. arXiv: 2410.14602 [cs.LG].
- [19] L. van der Maaten dan G. Hinton, "Memvisualisasikan Data menggunakan t-SNE," *J. Mach. Learn. Res.*, vol. 164, hlm. 2579–2605, 2008, ISSN: 02624079.
- [20] A. Halevy, P. Norvig, dan F. Pereira, "Keefektifan data yang tidak masuk akal," *Sistem Intelijen IEEE*, vol. 24, no. 2, hlm. 8–12, 2009, ISSN: 15411672.